

1st Project - Deep Reinforcement Learning

Ιωάννης Δίγκας

AEM: 4368

Τμήμα Πληροφορικής
Α.Π.Θ.

2026



Περιεχόμενα

1	Εισαγωγή	3
2	Περιβάλλον Εκπαίδευσης	3
3	Αλγόριθμος Deep Q-Network	4
3.1	Flatten DQN Baseline	4
3.2	CNN-DQN	5
4	Προεπεξεργασία Παρατηρήσεων	6
5	Πειραματική Διαδικασία	6
5.1	Hyperparameter tuning results	7
5.2	Final Hyperparameter Selection	8
6	Αποτελέσματα Εκπαίδευσης	8
7	Συμπεράσματα	10

1 Εισαγωγή

Στην εργασία μελετάται η επίλυση του περιβάλλοντος CarRacing-v3 της βιβλιοθήκης Gymnasium με χρήση Deep Q-Learning. Ο πράκτορας λαμβάνει οπτικές παρατηρήσεις από το περιβάλλον και επιλέγει διακριτές ενέργειες οδήγησης με στόχο τη μεγιστοποίηση της συνολικής ανταμοιβής ανά επεισόδιο. Υλοποιήθηκαν δύο προσεγγίσεις: ένα απλό DQN με πλήρως συνδεδεμένο νευρωνικό δίκτυο πάνω σε flattened εικόνα, και ένα CNN-DQN που επεξεργάζεται τις εικόνες ως οπτική είσοδο. Το απλό μοντέλο χρησιμοποιείται κυρίως ως baseline, ενώ το CNN-DQN αποτελεί την κύρια αρχιτεκτονική βαθιάς μάθησης της εργασίας.

2 Περιβάλλον Εκπαίδευσης

Το πρόβλημα που επιλέχθηκε είναι το CarRacing-v3 από τη βιβλιοθήκη Gymnasium. Στο περιβάλλον αυτό ο πράκτορας ελέγχει ένα αυτοκίνητο σε μία πίστα και λαμβάνει εικόνες ως παρατηρήσεις. Στόχος είναι η ολοκλήρωση της πίστας με όσο το δυνατόν μεγαλύτερη συνολική ανταμοιβή.

Η παρατήρηση του περιβάλλοντος είναι μία RGB εικόνα διαστάσεων $96 \times 96 \times 3$. Στην παρούσα εργασία χρησιμοποιήθηκε διακριτός χώρος ενεργειών, ώστε το πρόβλημα να μπορεί να προσεγγιστεί με Deep Q-Network.

Χαρακτηριστικό	Τιμή
Περιβάλλον	Gymnasium CarRacing-v3
Τύπος παρατήρησης	RGB εικόνα
Αρχική διάσταση παρατήρησης	$96 \times 96 \times 3$
Τύπος ενεργειών	Διακριτές ενέργειες
Αλγόριθμος	Deep Q-Learning
Βιβλιοθήκη υλοποίησης	PyTorch

Πίνακας 1: Βασικά χαρακτηριστικά του περιβάλλοντος εκπαίδευσης.

Action ID	Ενέργεια
0	Καμία ενέργεια
1	Στροφή αριστερά
2	Στροφή δεξιά
3	Επιτάχυνση
4	Φρενάρισμα

Πίνακας 2: Διακριτές ενέργειες του περιβάλλοντος CarRacing-v3.

3 Αλγόριθμος Deep Q-Network

Το Deep Q-Network είναι επέκταση του κλασικού Q-Learning, όπου η συνάρτηση αξίας $Q(s, a)$ προσεγγίζεται από νευρωνικό δίκτυο. Το δίκτυο λαμβάνει ως είσοδο την κατάσταση s και επιστρέφει μία εκτίμηση της αξίας για κάθε πιθανή ενέργεια a .

Η ενημέρωση γίνεται με βάση τον στόχο Bellman:

$$y = r + \gamma \max_{a'} Q_{\text{target}}(s', a')$$

όπου r είναι η ανταμοιβή, γ ο συντελεστής προεξόφλησης, s' η επόμενη κατάσταση και Q_{target} το target network. Για τερματικές καταστάσεις, ο δεύτερος όρος μηδενίζεται.

Η εκπαίδευση σταθεροποιείται με δύο βασικές τεχνικές:

- **Replay memory:** αποθήκευση παλαιότερων μεταβάσεων και τυχαία δειγματοληψία mini-batches.
- **Target network:** ξεχωριστό δίκτυο για τον υπολογισμό των target Q-values, το οποίο συγχρονίζεται περιοδικά με το policy network.

3.1 Flatten DQN Baseline

Στην πρώτη προσέγγιση, η εικόνα εισόδου $96 \times 96 \times 3$ κανονικοποιείται στο διάστημα $[0, 1]$ και μετατρέπεται σε μονοδιάστατο διάνυσμα μήκους 27648. Το διάνυσμα αυτό δίνεται σε ένα απλό πλήρως συνδεδεμένο νευρωνικό δίκτυο με ένα hidden layer.

Η αρχιτεκτονική είναι:

$$27648 \rightarrow H \rightarrow |\mathcal{A}|$$

όπου H είναι ο αριθμός των νευρώνων του κρυφού επιπέδου και $|\mathcal{A}|$ το πλήθος των διακριτών ενεργειών.

Η προσέγγιση αυτή χρησιμοποιείται ως baseline, επειδή δεν εκμεταλλεύεται τη χωρική δομή της εικόνας. Με άλλα λόγια, γειτονικά pixels στην εικόνα αντιμετωπίζονται ως ανεξάρτητα χαρακτηριστικά. Αυτό είναι περιοριστικό για οπτικά προβλήματα όπως η οδήγηση.

3.2 CNN-DQN

Στη δεύτερη προσέγγιση χρησιμοποιήθηκε συνελικτικό νευρωνικό δίκτυο. Η RGB εικόνα μετατρέπεται αρχικά σε grayscale και αλλάζει μέγεθος σε 84×84 . Επιπλέον, χρησιμοποιείται στοίβαξη διαδοχικών frames, ώστε το δίκτυο να έχει πληροφορία κίνησης και όχι μόνο μία στατική εικόνα.

Η τελική είσοδος του CNN έχει μορφή:

$$4 \times 84 \times 84$$

όταν χρησιμοποιούνται 4 grayscale frames.

Το CNN αποτελείται από τρία συνελικτικά επίπεδα:

- Conv2D με 32 φίλτρα, kernel size 8 και stride 4.
- Conv2D με 64 φίλτρα, kernel size 4 και stride 2.
- Conv2D με 64 φίλτρα, kernel size 3 και stride 1.

Μετά τα συνελικτικά επίπεδα, η έξοδος γίνεται flatten και περνά από fully connected layer 512 νευρώνων, πριν παραχθούν τα Q-values για κάθε δυνατή ενέργεια.

Επίπεδο	Παράμετροι	Ενεργοποίηση
Conv2D	32 filters, 8×8 , stride 4	ReLU
Conv2D	64 filters, 4×4 , stride 2	ReLU
Conv2D	64 filters, 3×3 , stride 1	ReLU
Flatten	--	--
Linear	512 units	ReLU
Linear	$ \mathcal{A} $ outputs	--

Πίνακας 3: Αρχιτεκτονική του CNN-DQN.

4 Προεπεξεργασία Παρατηρήσεων

Για το απλό Flatten DQN, η εικόνα εισόδου κανονικοποιείται διαιρώντας τις τιμές των pixels με 255 και στη συνέχεια μετατρέπεται σε μονοδιάστατο διάνυσμα.

Για το CNN-DQN εφαρμόζεται διαφορετική προεπεξεργασία:

- Μετατροπή της RGB εικόνας σε grayscale.
- Αλλαγή μεγέθους από 96×96 σε 84×84 .
- Κανονικοποίηση των pixel values στο διάστημα $[0, 1]$.
- Στοίβαξη 4 διαδοχικών frames.

Η στοίβαξη frames είναι απαραίτητη, επειδή από μία μόνο εικόνα δεν μπορεί να εξαχθεί εύκολα πληροφορία για την ταχύτητα και την κατεύθυνση της κίνησης.

5 Πειραματική Διαδικασία

Η εκπαίδευση πραγματοποιήθηκε σε δύο στάδια. Αρχικά υλοποιήθηκαν δύο βασικές αρχιτεκτονικές: ένα απλό Flatten DQN και ένα CNN-DQN. Στη συνέχεια πραγματοποιήθηκε μικρή αναζήτηση υπερπαραμέτρων για κάθε μοντέλο.

Η αναζήτηση υπερπαραμέτρων έγινε σε δύο στάδια:

- **Stage 1:** γρήγορο screening διαφορετικών υποψήφιων ρυθμίσεων για μικρό αριθμό επεισοδίων.
- **Stage 2:** επανεκπαίδευση των καλύτερων υποψήφιων ρυθμίσεων με περισσότερα seeds και περισσότερα επεισόδια.

Οι υποψήφιες ρυθμίσεις διαφοροποιούσαν παραμέτρους όπως learning rate, batch size, discount factor, replay memory size, epsilon decay και target network sync rate.

5.1 Hyperparameter tuning results

Candidate	Mean Train Reward	Std	Βασική αλλαγή
cnn_low_lr_large_replay	-56.34	0.38	Lower LR, larger n
cnn_fast_updates	-56.35	0.49	Higher LR, smaller
cnn_lower_gamma_quick_sync	-56.67	0.86	Lower γ , faster s

Πίνακας 4: Καλύτερες ρυθμίσεις από το hyperparameter tuning για το CNN-DQN.

Candidate	Mean Train Reward	Std	Βασική αλλαγή
flatten_big_hidden_long_horizon	-48.14	6.86	Larger hi
flatten_stable_large_batch	-50.29	3.07	Lower LR
flatten_small_hidden_quick_decay	-54.83	7.62	Smaller hid

Πίνακας 5: Καλύτερες ρυθμίσεις από το hyperparameter tuning για το Flatten DQN.

Η αναζήτηση υπερπαραμέτρων δεν είχε στόχο εξαντλητική βελτιστοποίηση, αλλά γρήγορη σύγκριση διαφορετικών ρυθμίσεων. Για τον λόγο αυτό χρησιμοποιήθηκαν σύντομα training runs στο πρώτο στάδιο και περισσότερα seeds στο δεύτερο στάδιο για τις καλύτερες ρυθμίσεις. Οι τελικές επιλογές των υπερπαραμέτρων ήταν οι εξείς:


5.2 Final Hyperparameter Selection

Παράμετρος	Flatten DQN	CNN-DQN
Environment	CarRacing-v3	CarRacing-v3
Continuous actions	False	False
Learning rate	5×10^{-5}	1×10^{-4}
Discount factor γ	0.99	0.97
Replay memory size	50,000	50,000
Mini-batch size	128	64
Epsilon initial	1.0	1.0
Epsilon decay	0.995	0.995
Epsilon minimum	0.05	0.05
Target sync rate	3,000 steps	500 steps
Stop reward threshold	700.0	700.0
Hidden dimension	256	512
Frame stack	--	4
Image size	$96 \times 96 \times 3$ flattened	84×84 grayscale
Checkpoint interval	--	250 episodes
Gradient clipping	--	10.0
Max episodes	1,000	1,000
Loss function	MSE	Smooth L1
Optimizer	Adam	Adam


Πίνακας 6: Τελικές υπερπαράμετροι των δύο μοντέλων.

6 Αποτελέσματα Εκπαίδευσης

Στα διαγράμματα παρουσιάζεται η ανταμοιβή ανά επεισόδιο, ο κινούμενος μέσος όρος των τελευταίων 100 επεισοδίων και η πορεία του epsilon κατά την εκπαίδευση.



Σχήμα 1: Εξέλιξη ανταμοιβής και epsilon decay για το Flatten DQN.



Σχήμα 2: Εξέλιξη ανταμοιβής και epsilon decay για το CNN-DQN.

Στο Flatten DQN παρατηρείται σημαντική αύξηση της ανταμοιβής μετά τα πρώτα επεισόδια, με τον κινούμενο μέσο όρο να καταλήγει περίπου στην περιοχή των 700 μονάδων ανταμοιβής. Παρά την απλή αρχιτεκτονική, το μοντέλο καταφέρνει να μάθει πολιτική που ολοκληρώνει την πίστα σε αρκετές δοκιμές.

Στο CNN-DQN η βελτίωση είναι πιο σταδιακή. Αυτό είναι αναμενόμενο, επειδή το CNN εκπαιδεύεται απευθείας από οπτική

πληροφορία και έχει περισσότερες παραμέτρους. Παρόλα αυτά, η χρήση συνελικτικών επιπέδων είναι πιο κατάλληλη για το συγκεκριμένο πρόβλημα, επειδή αξιοποιεί τη χωρική δομή της εικόνας.

Μοντέλο	Successes	Success Rate	Mean Reward	Mean Lap Time
Flatten DQN	4/5	80.0%	572.14	21.4s
CNN-DQN final	5/5	100.0%	856.82	13.8s

Πίνακας 7: Σύγκριση τελικών μοντέλων στην αξιολόγηση χωρίς rendering.

Checkpoint	Successes	Success Rate	Mean Reward	Mean Lap Time
250 episodes	0/5	0.0%	-574.82	--
500 episodes	1/5	20.0%	124.34	59.5s
750 episodes	5/5	100.0%	698.00	30.4s
1000 episodes	5/5	100.0%	825.82	17.0s

Πίνακας 8: Αξιολόγηση των CNN-DQN checkpoints χωρίς rendering.

Τα αποτελέσματα δείχνουν ότι το CNN-DQN βελτιώνεται σημαντικά όσο αυξάνονται τα επεισόδια εκπαίδευσης. Στα 250 επεισόδια δεν ολοκληρώνει κανέναν γύρο, ενώ στα 500 επεισόδια αρχίζει να εμφανίζει περιορισμένη επιτυχία. Από τα 750 επεισόδια και μετά επιτυγχάνει 100% success rate στην αξιολόγηση των 5 επεισοδίων. Το τελικό CNN-DQN μοντέλο πέτυχε την καλύτερη συνολική απόδοση, με mean reward 856.82 και best lap time 9.7s, ξεπερνώντας το Flatten DQN τόσο σε μέση ανταμοιβή όσο και σε χρόνο ολοκλήρωσης.

7 Συμπεράσματα

Στην παρούσα εργασία υλοποιήθηκαν και συγκρίθηκαν δύο προσεγγίσεις Deep Q-Learning για το περιβάλλον CarRacing-v3: ένα απλό Flatten DQN και ένα CNN-DQN. Από τα αποτελέ-

σματα προκύπτει ότι ακόμη και ένα σχετικά απλό πλήρως συνδεδεμένο νευρωνικό δίκτυο μπορεί να αποδώσει ικανοποιητικά στο συγκεκριμένο πρόβλημα. Παρότι το Flatten DQN δεν αξιοποιεί τη χωρική δομή της εικόνας, κατάφερε να μάθει πολιτική οδήγησης που σε αρκετές περιπτώσεις ολοκληρώνει επιτυχώς την πίστα.

Ωστόσο, το CNN-DQN αποτελεί καταλληλότερη αρχιτεκτονική για προβλήματα που βασίζονται σε οπτική πληροφορία. Σε αντίθεση με το Flatten DQN, το οποίο μετατρέπει ολόκληρη την εικόνα σε ένα μονοδιάστατο διάνυσμα pixels, το CNN επεξεργάζεται την εικόνα με συνελκτικά φίλτρα και μπορεί να εντοπίζει τοπικά χωρικά χαρακτηριστικά, όπως τη θέση του δρόμου, τις στροφές και τα όρια της πίστας. Επιπλέον, με τη χρήση frame stacking το CNN-DQN δεν λαμβάνει υπόψη μόνο την τρέχουσα εικόνα, αλλά και προηγούμενα διαδοχικά frames. Έτσι, το μοντέλο έχει καλύτερη πληροφορία για την κίνηση του αυτοκινήτου, την κατεύθυνση και την ταχύτητα, στοιχεία που δεν είναι άμεσα διαθέσιμα από μία μόνο στατική εικόνα.

Η τελική αξιολόγηση χωρίς rendering έδειξε ότι το CNN-DQN πέτυχε καλύτερη συνολική απόδοση από το Flatten DQN, τόσο ως προς τη μέση ανταμοιβή όσο και ως προς τον χρόνο ολοκλήρωσης της πίστας. Παρόλα αυτά, η απόδοση του Flatten DQN ήταν απροσδόκητα καλή για την απλότητα της αρχιτεκτονικής του. Αυτό δείχνει ότι το συγκεκριμένο περιβάλλον μπορεί να προσεγγιστεί ακόμη και με απλούστερα μοντέλα, αν και αυτά έχουν περιορισμούς ως προς τη σταθερότητα και τη γενίκευση της πολιτικής τους.

Οπτική Παρατήρηση Επισοδίων των Μοντέλων Κατά την οπτική παρατήρηση των επεισοδίων με rendering, παρατηρήθηκαν διαφορετικές αδυναμίες στα δύο μοντέλα. Το Flatten DQN σε ορισμένες περιπτώσεις εμφάνιζε ασταθή συμπεριφορά, όπως επαναλαμβανόμενες περιστροφές ή κινήσεις χωρίς σαφή κατεύθυνση, γεγονός που μπορούσε να οδηγήσει σε απώλεια της πορείας μέσα στην πίστα. Αντίθετα, το CNN-DQN παρουσίασε γενικά πιο σταθερή οδηγική συμπεριφορά, αν και σε ορισμένες περιπτώσεις έκανε απότομες στροφές που μπορούσαν να το βγά-

λουν εκτός πίστας. Παρά τις αδυναμίες αυτές, και τα δύο μοντέλα κατάφεραν να μάθουν λειτουργικές πολιτικές οδήγησης.

Συνολικά, το CNN-DQN θεωρείται η πιο κατάλληλη προσέγγιση για το συγκεκριμένο πρόβλημα, επειδή αξιοποιεί καλύτερα τη μορφή της εισόδου και την ακολουθιακή πληροφορία των frames. Το Flatten DQN παραμένει χρήσιμο ως baseline, καθώς έδειξε ότι ακόμη και μία απλή αρχιτεκτονική μπορεί να επιτύχει αξιοσημείωτη απόδοση. Ως μελλοντική βελτίωση, θα μπορούσαν να εξεταστούν πιο εξελιγμένες παραλλαγές του DQN, όπως Double DQN ή Dueling DQN, καθώς και μεγαλύτερη και πιο συστηματική αναζήτηση υπερπαραμέτρων.